

## 資料探勘 作業二

2025-10-21

### Part I. 手寫數字影像特徵擷取

#### 1. 使用 PCA 擷取特徵

- a. 畫出前十特徵（主成分）。
- b. 取出第 55, 1136, 2082, 2120 以及第 5422 張影像，以及其分別對應至前五特徵（PC1~PC5）的係數，完成以下表格。觀察這些數字影像，以及所對應的主成分係數，你是否可以看到他們之間的連結？請簡述。

|   | PC1   | PC2   | PC3   | PC4   | PC5   |
|---|---|---|---|---|---|
| 55<br>   |  |  |  |  |  |
| 1136<br> |   |   |   |   |   |
| 2028<br> |   |   |   |   |   |
| 2120<br> |   |   |   |   |   |
| 5422<br> |   |   |   |   |   |

2. 使用 NMF 擷取特徵 ( 基底 )

- a. 設定特徵 ( 基底 ) 數為 25。任選十個特徵 ( 基底 )，**畫出**這些特徵。

注意：你必須先檢查 relative error 的趨勢，確認你得到的特徵滿足了你所定義的收斂條件。

- b. 觀察 2a. 中的 NMF 基底與 1a. 中的 PCA 主成分，在外觀與結構上的不同，以此說明他們在呈現資料的「組成方式」上有何差異。

- c. 針對 2b. 中觀察到的差異，請說明造成這些差異的關鍵因素。換句話說，NMF 與 PCA 在設定或限制條件上有哪些不同？這些差異如何導致 2b. 所看到的現象？

- d. 在 1a. 中我請你畫出前十個主成分，但在 2a. 中我請你畫出任選十個特徵，而不是前十特徵。請你推測，這是因為我想要向你強調 PCA 與 NMF 所找出的特徵組在哪一個性質上的差異？

3. 使用 t-SNE 擷取特徵 ( 投影維度 )

- a. 將 t-SNE 之投影維度設為三維。這三個維度是否能像 PCA 的主成分與 NMF 的基底，對應到可視化的影像，如 1a. 與 2a. 的作法？若可以，請**畫出**這三個維度；若不可以，請說明原因。

## Part II. 手寫數字影像降維與分群

### 1. 視覺三維特徵空間中的群聚分布

此處我們僅以三維特徵空間為基準，比較 PCA ( 擷取前三個主成分 )、NMF ( 分解至三個基底 ) 與 t-SNE ( 投影至三維 ) 的表現，觀察它們是否能在新的特徵空間中清楚區分不同數字的群組。

你可以使用 `rgl:: plot3d(三維特徵空間的座標, col=影像的數字標籤)` 來呈現影像於三維空間中的分佈。

### 2. 評估 k 維特徵空間中的群聚分布

- 對於 PCA，選擇 [解釋原資料約 75% 變異] 的主成分數量，作為特徵空間的維度。
- 對於 NMF，使用 50 個基底建構特徵空間。請確認這 50 個基底所產生的重建誤差，與使用 a. 中 [解釋 75% 變異量] 之主成分所產生的誤差相近。重建誤差定義為：

$$\sum_{i=1}^{28} \sum_{j=1}^{28} (x_{ij} - \tilde{x}_{ij})^2$$

- 對於 t-SNE，使用三維建構特徵空間。

分別使用原始影像 ( 784 維 )，以及原始影像於上述 a、b、c 三個特徵空間中的座標，以 K-Means 演算法 ( 設定  $k=10$  ) 對 MNIST 手寫數字影像進行分群，並以下方兩種指標評估分群表現：

- 外在指標：Purity，以 [影像的數字標籤] 為標準。

可使用 `funtimes::purity()`

- 內在指標：Silhouette coefficient 的分布

可使用 `cluster:: silhouette()`

對於內在指標，請提供兩種計算結果：使用原資料 ( 784 維 )，以及使用特徵座標。

根據上述指標，比較三種特徵擷取方法對於 MNIST 分群結果的影響與幫助。

### Part III. 動物類別分群與特徵類別分析

資料 hw2\_data\_animals.csv 記錄了同學們以 [自己的觀點] 對動物做分類的結果。每一位同學的分類標準不同：有些同學可能著眼於物種屬性，有些可能是以棲息地分類，有些同學可能沒有具體訂標準，憑藉的是直覺。不論同學們採用何種視角做分類，我們都可以將每位同學的分類，視為動物的一種特徵。也就是說，此份資料記錄了每種動物的 24 項特徵。有些特徵（同學）描述的角度可能很相近，有些則可能很不同。以下請同學使用 Homogeneity Analysis 分析此資料。

1. 視覺化 [動物] 與 [變數類別] 於二維特徵空間中之相近度
  - a. 以 HOMALS 二維特徵呈現動物的散佈圖。簡述你在圖中所看到的。
  - b. 以 HOMALS 二維特徵呈現變數類別之散佈圖。請從圖中舉兩個例子。每個例子請呈現：哪兩位同學的哪兩個類別所在的位置十分相近？檢視原始資料，說明它們的位置為何相近。
  - c. 以 HOMALS 二維特徵呈現
    - (i) 鱷魚的位置，以及 [每位同學所指派鱷魚之類別] 的位置
    - (ii) 鴕鳥的位置，以及 [每位同學所指派鴕鳥之類別] 的位置這些位置所呈現的遠近關係，與你所學到的 HOMALS 樣本與類別位置之解的設定，看起來是否相符合？簡單說明你的想法。
2. 動物的群聚分析
  - a. 設定 HOMALS 投影維度為 30 維。**畫出 eigenvalues** 隨著維度數改變的趨勢。觀察 eigenvalues 是否在這其中已開始趨於平緩。
  - b. 以投影 30 維為基準，計算前 20 維所解釋之變異百分比。
  - c. 根據前 20 維之 HOMALS 座標，使用 Hierarchical Clustering 配合 Wald linkage 做動物的群聚分析，並且以 dendrogram 展現群聚結構。你喜歡這個 dendrogram 的模樣嗎？簡述你的想法。
  - d. 基於這 20 維所對應的 eigenvalues 值是由大到小排列的性質，你認為 c. 的做法是否合理？
    - (i) 檢查動物的 HOMALS 座標在每一個維度的變異是否相同。你所檢查的結果與 HOMALS 求解的設定是否相符合？
    - (ii) 根據 c. 的檢查結果，你認為我們是否應該進一步調整動物的 HOMALS 座標於每個維度的變異，並且以調整後的座標做群聚

分析？說明你的看法。

- (iii) 不論你在 c. 的答案為何，請你以 eigenvalues 調整動物的 HOMALS 座標，即：對於解釋變異越大的維度，我們給予該維度座標較大的權重：

```
hhx=hh$objscores[, 1:p]  
hhx.w=sweep(hhx, 2, sqrt(e[1:p]), `*`)
```

使用調整後的座標，重新做一次 c. 中的分群。這次分群結果的 dendrogram 與 c. 中的 dendrogram 的差異在哪裡？你比較喜歡哪一個 dendrogram？說明你的原因。